

# 受脑认知与神经科学启发构建的人工智能基础模型

易凯

人工智能与机器人研究所

yikai2015@stu.xjtu.edu.cn

## Abstract

本文将主要探讨受脑认知与神经科学启发构建的人工智能基础模型。*Remains.*

## 1. 前馈神经网络

前馈神经网络（feedforward neural network）是一种网络中各个单元之间不成循环的网络结构组织形式。当前，其在许多领域有着广泛而深入的应用。其中先驱性的工作之一是多层感知机（multilayer perceptron）的提出 [1], 它通过非线性激活函数，能够极为有效地解决线性不可分问题。此外，如今被广泛使用的深度神经网络 (Deep Neural Networks) 通过将多层感知机层数加深，每层加宽以及一些实用性技巧 (如 dropout, 随机梯度下降等) 在多种任务上取得了媲美人类，甚至是超过人类的性能 [2]。在本章节中，我们将在发掘 MLP 以及 DNN 的脑认知以及神经科学的基础之上，对两个的相关概念，模型结构以及训练策略等基本情况分别进行回顾。

### 1.1. 多层感知机

生物神经网络（biological neural network）由大量的神经元构成，他们之间复杂的连接与交互共同承担了人脑活动的基本功能。多层感知机是一种具有代表性的受脑认知启发的前馈人工神经网络，接下来我们将对其基本模型以及学习算法进行分析。

与人脑由多个不同的子系统通过复杂交互方式解决各种任务相似，一个典型的多层感知机由层次化的层（layer）通过全连接组成。多层感知机中具有三层，分别为输入层（input layer），隐含层（hidden layer）以及输出层（output layer），其中隐含层可能具有多层。每

个层有许多个节点构成，每层的节点之间相互不连接，我们仿照人脑的相关结构，也称其为神经元（neuron）。为了模拟人脑中子系统之间复杂的交互方式，前一层都与其后一层的每个神经元使用非线性激活函数进行全连接。这个非线性的连接方式使得多层感知机能够解决多种复杂的任务，如语音识别 [3] 和字符识别 [4] 等。多层感知机的拓扑结构如下图所示：




图 1: 多层感知机

在训练阶段，多层感知机使用反向传播（backpropagation）这一广泛使用的监督学习算法来进行网络连接权的更新。总的来说，多层感知机就像一个高阶的非线性函数  $f(\cdot)$ ，该模型的目的在于计算  $Y = f(X)$ ，其中  $X$  是输入神经元向量， $Y$  是输出神经元向量。

### 1.2. 深度神经网络

深度神经网络是一种计算模型，其通过不同层次的抽象，能够对数据及其特征进行不同层次的学习与表征 [5]。当前，其在许多复杂任务处理上取得了重大的突破与进展，如图像分类 [6], [7], 决策与控制 [8], [9]. 将深度神经网络归纳为前馈有一些不恰当，同时其认知科学的背景并不是太强，是否需要将其引入到基础模型的部分？

## 2. 动态神经网络

神经网络根据是否有延迟和反馈环节可以将其区分为静态神经网络和动态神经网络两大类，其中含有延迟或者反馈环节的神经网络称之为动态神经网络。由于人脑对于信息的编码以及处理过程中，延迟与反馈是其中的重要部分，因此其具有很强的生物真实性。该部分将介绍两种典型的动态神经网络构成的人工智能基础模型，一种是以 Hopfield 神经网络为代表的联想记忆模型，另外一种混沌神经网络。

### 2.1. 联想记忆模型 – Associative Memory Model

记忆是生物神经网络的一个重要功能，它在生物检测和控制生存环境的过程中起着关键作用。鉴于记忆在生物神经网络中的重要地位，对生物记忆机制和模型的研究，既可以增进人们对于人脑工作机理的理解，同时有利于设计具有生物学依据的更加鲁棒的神经网络模型。

与以计算机存储数据为代表的机械记忆形式相比，生物记忆具有一些独特的特征，主要可以归纳为四点：一是分布式表示和存储信息，二是检索出的信息与输入信息在内容上具有关联性，三是存储和回忆信息的动态性，四是与其他信息处理过程密切结合。鉴于生物记忆的第二个特点，人们通常将生物记忆称之为联想记忆。




图 9-1 离散 Hopfield 网络




图 9-2 Hopfield 网络的网状结构

图 2: Hopfield 神经网络的一般化结构.  $x_i$  表示第  $i$  个神经元,  $\cdot$  表示多个神经元之间的乘积。

Hopfield 神经网络是一种极为流行的动态神经网络。其根据输入信息的连续性与否，可以分为离散型 Hopfield 神经网络以及连续性 Hopfield 神经网络这两类，其中前者经常被用来解决各种优化问题，而后者则被广泛地应用于联想记忆 [10], [11]。关于 Hopfield 神经网络的一般化结构在表 2 中进行了呈现。Hopfield 神经网络的优化目标是最小化能量函数，通常而言，其可

以减小到零，这也就意味着连续型的 Hopfield 神经网络联想出了与输出模式相似的模式。典型的能量函数的定义如下：

$$E = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n w_{ij} x_i x_j + \sum_{i=1}^n \theta_i x_i \quad (1)$$

通过一定地学习算法指导，经过循环迭代，Hopfield 神经网络很可能收敛于全局最优，从而联想出与输入模型最为接近的模式。神经网络联想出某种对应模式的标志是能量函数降为 0。

通过有限次数的循环迭代，最终 Hopfield 神经网络将很可能收敛到全局最优，从而联想出与输入相似的模式。由于深度学习只能收敛到局部最优，而人脑是可以实现全局最优的，因此在这个层面上，基于 Hopfield 神经网络的联想记忆模型更具有生物相似性。

当前，最经典且具有生物学可信性的 Hopfield 神经网络学习算法为 Hebb 学习算法，其表明一种反射活动的持续或者重复容易产生持久的细胞改变，从而增强其稳定性 [12], [13]。假设一 Hopfield 神经网络具有  $N$  个神经元，记忆了  $M$  个不同的模式向量  $\xi_\alpha = (\xi_{\alpha 1}, \dots, \xi_{\alpha N})^T$ ，利用 Hebb 学习得到的网络连接权矩阵  $W$  为：

$$W = \sum_{\alpha=1}^M \xi_\alpha (\xi_\alpha)^T \quad (2)$$

设连接权矩阵  $W$  的元素为  $w_{ij} (i \leq i, j \leq N)$ ，则

$$w_{ij} = \sum_{\alpha=1}^M \xi_{\alpha i} \xi_{\alpha j} \quad (3)$$

由于初始的神经网络能量函数降为零的速度较为慢，而且使用 Hebb 学习规则的 Hopfield 网络最大记忆容量较小，理论值为  $K^{max} \approx 0.14N$ 。为了缓解上述两个问题，有大量的研究在提升 Hopfield 神经网络的性能上做出了努力。Krotov 等人 [11] 在原始网络的基础上提出了 Dense Associative Memory 模型，能够以更快的收敛速度对网络权值进行异步更新 [11]，同时其在某种程度上也提升了 Hopfield 神经网络的鲁棒性 [14]。此外，由于 Hebb 学习间接导致了 Hopfield 神经网络较小的记忆容量，其后提出的诸如伪逆法 [15], [16] 以及感知机算法一定程度地提升了网络的记忆容量，但是其全局性也丧失了一定的生物学基础。当前，Hopfield 神经网络的迭代，由于神经元数量较多，迭代随机初始

化生成模型很可能导致网络进入混沌状态，也就意味着网络自身没能联想到与输入最为相似的模式，尽管在这一领域已经做出了一些努力 [17]，但至今其仍然是悬而未决的问题。

## 2.2. 混沌神经网络

混沌现象在许多的领域是普遍存在的 [18]。在神经科学领域，混沌动态性不仅存在于神经元上，而且存在于神经网络和人脑之中 [19], [20]。

可以考虑将混沌神经网络与 Hopfield 神经网络两者进行整合。使得其切入点为网络的动态性作为神经网络。

## 3. 生成模型

生成模型是一类极为重要的模型，其能够生成满足一定数据分布的数据。在认知科学中，想象力机制是具有典型性的一部分，而生成模型的这种特征，则从一定程度上正是想象力的一种量化表征，通过这种模型，我们能够创造新的图像以及新的有价值的概念。在这一部分，我们将对两类典型的生成模型进行分析，其分别为变分自动编码器（variational autoencoder）和生成对抗模型（generate adversarial model）。

### 3.1. 变分自动编码器

人脑的信息编码问题也就是分析人在受到外部刺激时如何将信息进行处理的过程。受到脑神经科学的启发，对于信息的编码在人工智能系统之中也发挥着重要作用。自动编码器主要是生成与输入信息尽可能相似度高的输出信息。其首先通过 encoder 网络将输入信息编码为一串隐含向量，然后通过 decoder 将隐含向量解码，接着信息输出。常用均方差作为编码器性能的衡量标准。其通过反向传播算法进行网络节点之间连接权重值的训练。

由于通过传统的编码器我们并不能解决任意生成图片的问题，因为我们没有办法去直接构造隐含向量，该向量是通过对应的输入信息来得到，因此引入了变分自动编码器的相关概念。VAE 的核心概念是在编码过程中增加一些限制，迫使其生成的隐含向量能够粗略地遵循一个标准的正态分布。我们仅仅需要给它一个标准正态分布的随机隐含向量，这样通过解码器我们就可以生成我们想要的图片，而不是给它一张原始图

片然后对其进行编码。VAE 的基本模型结构如图 3。 3

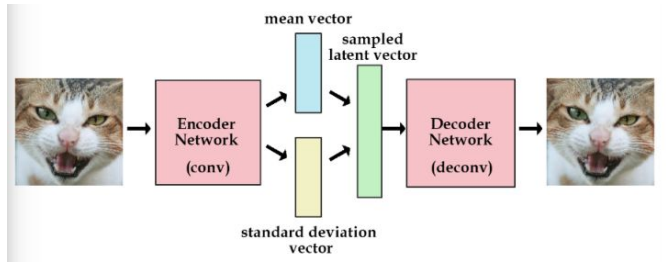


图 3: 变分自动编码器的基本结构。输入信息通过编码网络，得到两个向量，一个表示均值，另外一个表示标准差，然后通过这两个统计量在高斯分布基础上合成隐含向量。然后得到概率分布之后进行对应信息的解码。

我们的目标是希望得到的隐含向量越靠近高斯分布，也就是希望编码之后其均值为 0，而标准差为 1。一般而言，我们使用 KL 散度来衡量两种分布的相似程度，也就是通过如下的公式：

$$DKL(P||Q) = \int_{-\infty}^{\infty} p(x) \log \frac{p(x)}{q(x)} dx \quad (4)$$

变分自动编码器在很多的领域有着广泛的应用，其可以进行高维数据可视化（通过编码器将高维的数据映射到较低维度的可直观展示的空间，进行数据特征及其拓扑结构的直观分析）[21]，缺失数据补全（在部分维度缺失或者不准确的情况下，通过相关信息对其进行填补）[22] 以及半监督学习（通过生成满足一定约束条件的大量无标注数据，与一小部分标注数据结合，来进行学习）[23]。

### 3.2. 生成对抗模型

在最大似然估计以及其他相关策略的基础之上，很多概率计算的模拟非常之难。这就一定程度上促进了生成对抗模型的引入 [24]。该模型的训练与优化是一个动态博弈的过程，模型由两部分构成，其分别为生成器 G 以及判别器 D（如图 4），其中 G 的目标是生成让判别器无法判断输入的是真实的训练数据还是通过 G 生成的伪数据，而 D 的目标是尽可能去辨别由生成器产生的伪数据。判别器的优化函数定义为：

$$\max_D E_{x \sim P_r} [\log D(x)] + E_{x \sim P_g} [\log(1 - D(x))] \quad (5)$$

## Generative Adversarial Network

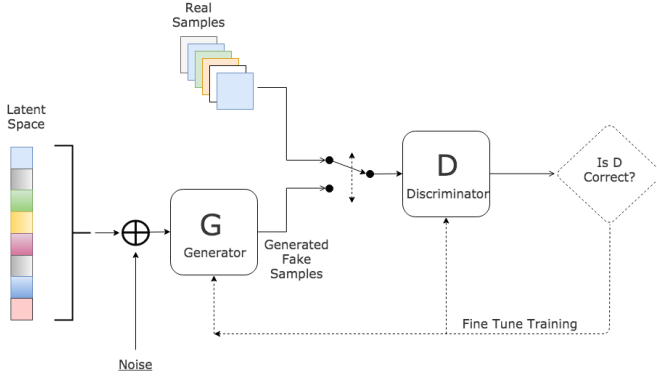


图 4: 生成对抗模型

其中，D 为判别模型，对任何输入  $x$ ， $D(x)$  的输出是 0-1 范围内的一个实数，用来判断这一数据是一真实数据的概率。其中， $P_r$ ,  $P_g$  分别代表真实图像的分布和生成图像的分布。类似地，生成模型的目标是让判别模型无法区分真实图片和生成图片，那么整个的优化目标函数为：

$$\min_g \max_D E_{x \sim P_r} [\log D(x)] + E_{x \sim P_g} [\log(1 - D(x))] \quad (6)$$

生成对抗网络的优化过程是，对 D 和 G 进行迭代训练。也就是首先固定 D，然后优化 G；接着固定 G，然后优化 D。直到网络收敛。对抗网络强大的概率分布表征能力，也被应用于许多领域，如超精度图像生成 [25]，语言和音乐生成 [26] 等。

## 4. Deep Q-Networks

强化学习 (reinforcement learning) 是一个与神经科学和认知科学密切关联的学科，其学习的基本途径是使用一种称之为 try-and-error 的试错机制实现学习。深度强化学习 (deep reinforcement learning) 是将深度学习和强化学习结合起来，从而实现从感知到行为的一种端对端学习算法，其与人类一样，能够对输入的感知信息，通过网络直接输出对应的动作，没有 hand-crafted 工作。深度强化学习使智能体具有了自主学习解决某项任务，甚至是多项任务的能力。

深度强化学习的学习对象是 agent，其可以通过做出一定的 action 与 environment 直接交互，environment

能够对该 action 做出一定的反应，也被称之为 reward<sup>4</sup>，agent 然后根据 reward 进行策略的调整，这就是一个完整的深度强化学习的学习过程，其与人类学习一样，具有高度的探索性，同时也能与现有知识进行整合。

一般而言，将优化的策略对象称之为 Q，Q 值越接近于最优优化策略则表示策略越好，在表征上就是 Q 值的绝对大小。Value iteration 是常用的 Q 值更新策略，通过使用每次得到的 reward 和之前的 Q 值对当前 Q 值进行更新。Deep Q-Learning [8] 的思想也是完全根据 value iteration 得到，但要明确一点是 value iteration 每次都把所有的 Q 值更新一遍，也就是所有的状态和动作。但事实上在实际情况下我们没办法遍历所有的状态，还有所有的动作，我们只能得到有限的系列样本。因此，只能使用有限的样本进行操作。为了处理这一问题，Deep Q-Network 提出了一种新的 Q 值更新方法：

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha(R_{t+1} + \lambda \max_a Q(S_{t+1}, a) - Q(S_t, A_t)) \quad (7)$$

虽然根据 value iteration 计算出 target Q 值，但是这里并没有直接将这个 Q 值（是估计值）直接赋予新的 Q，而是采用渐进的方式类似梯度下降，朝 target 迈进一小步，取决于  $\alpha$ ，这就能够减少估计误差造成的影响。类似随机梯度下降，最后可以收敛到最优的 Q 值。

其直观表述如下：

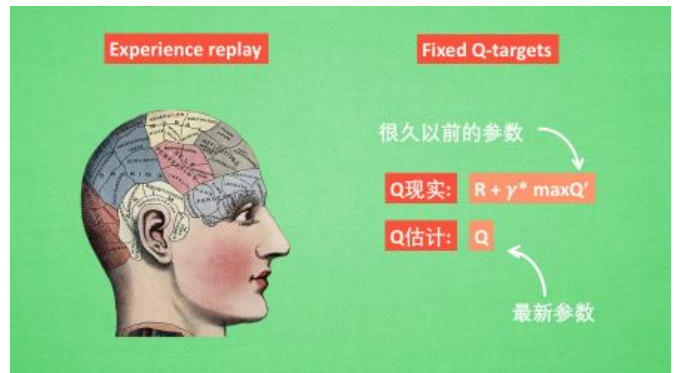


图 5: Deep Q-Networks

关于 Deep Q-Network 的优化，用到了 exploration 和 exploitation 之间的权衡，exploration，也就是探索位置的动作会产生的效果，有利于对 Q 值的更新，获得

更新神经网络而 exploitation 则利用现有策略, 若相对来说不好更新出更好的 Q 值, 但是可以得到更好的测试效果来判断算法的有效性。将两者的结合也就是所谓的  $\epsilon - greedy$  策略,  $\epsilon$  一般是一个很小的值, 作为选取随机动作的概率值。可以更改  $\epsilon$  的值从而得到不同的 exploration 和 exploitation 的比例。

## 5. 脉冲神经网络

当前, 深度神经网络在多个数据集上取得了重大的突破与进展, 如图像分类 [6], [7], 决策与控制 [8], [9]. 但是其与神经元对于信息的编码上还存在一定差异。人脑对信息的编码是基于脉冲序列的。当脉冲信号强度达到一定的峰值, 也就是动作电位, 对应神经元产生一定的输出, 其他状态下不输出。总的来说, 其是一种连续性的信号, 而不是像深度神经网络这样, 采用离散的数值信号进行编码。脉冲神经网络是一类极为重要的具有强生物学依据的基础模型, 其设计主要由脉冲编码、神经元模型和学习规则三部分构成。以下将主要回顾神经元模型和学习规则这两个部分。

### 5.1. 脉冲编码

脉冲编码也就是将样本数据编码成脉冲序列的过程, 当前使用较多的是 Rate Coding, Temporal Coding 等编码方式 [27]。

### 5.2. 神经元模型

最早的神经元模型由 Hodgkin 等人在 1952 年提出 [28], 被命名为 HH。虽有陆续有各种形式的神经元模型被提出, 其中具有代表性的两种是 Izhikevich 模型 [29] 和 LIF (Leaky-Integrate-and-Fire) 模型 [30]。

以 LIF 神经元模型为例, 其数学表达形式如下:

$$\tau \frac{dV}{dt} = -(V - V_r) + RI \quad (8)$$

其中,  $\tau = RC$  为膜时间常数,  $R$  为膜电阻,  $C$  为膜电容,  $V$  为膜电位,  $V_r$  为复位电位,  $I$  为注入电流。当膜电位超过一个固定的阈值时, 神经元发放一个脉冲, 并很快地降至复位电位并维持一小段时间, 然后接受前段突触的输入脉冲重新升高膜电位。各种神经元模型均类似于此过程。

### 5.3. 学习规则

学习规则又分为无监督和有监督, 其中无监督学习方法以 STDP (Spike-Timing-Dependent Plasticity) [31], [32] 为代表, 而有监督学习包括 Tempotron [33], ReSuMe (Remote Supervised Method) [34] 和 SpikeProp [35] 等。

以 Tempotron 为例, 阈值下的后突触膜电位 (PSPs, Postsynaptic Potentials) 为所有输入脉冲的加权和:

$$V(t) = \sum_i \omega_i \sum_{t_i} K(t - t_i) + V_{rest} \quad (9)$$

其中,  $t_i$  表示第  $i$  个输入神经元的脉冲发放时刻 (注: 输入神经元在一个时间窗口内可能发放多个脉冲, 也可能没有脉冲发放)。  $K(t - t_i)$  为输入神经元的第  $i$  个发放脉冲对后突触膜电位的贡献, 具体为:

$$K(t - t_i) = V_0 (\exp[-(t - t_i)/\tau] - \exp[-(t - t_i)/\tau_s]) \quad (10)$$

其中,  $\tau$  和  $\tau_s$  为时间常数。为使得  $K(t - t_i)$  的幅值为 1, 先设定  $V_0 = 1$ , 然后求导得到最大膜电位时间代入  $K(t_{max} - 0)$ , 求其倒数得到归一化因子  $V_0$  为:

$$V_0 = 1/K(((\tau\tau_s \log(\tau/\tau_s))/(\tau - \tau_s)) - 0) \quad (11)$$

有监督学习的重点是如何更新突触连接权重  $i$ , 获得期望输出脉冲。而 Tempotron 算法的核心如下:

$$\Delta\omega_i = \lambda \sum_{t_i < t_{max}} K(t_{max} - t_i) \quad (12)$$

以二分类问题为例, 如上更新规则为: 首先分别求取类别 1 和类别 2 的最大膜电位时刻  $t_{max}$ 。假定样本为类别 1 时, 输出神经元发放脉冲, 而当样本为类别 2 时输出神经元不发放脉冲。那么只需要判断最大膜电位  $V(t_{max})$  与阈值电位  $V_{thr}$  的关系即可进行权重更新:

(1) 如当样本的真实类别为类别 1, 输入脉冲神经网络之后, 输出神经元在当前窗口时间范围内的最大膜电位大于阈值电位, 则发放一个脉冲且无需更新突触连接权重。而当最大膜电位小于阈值电位时, 需要根据如上公式更新连接权重, 且  $\lambda > 0$  以增强贡献比较大的连接权重。

(2) 反之, 如当样本的真实类别为类别 2, 输入脉冲神经网络之后, 输出神经元在当前窗口时间范围内



的膜电位网络于阈值电位，则不发放脉冲且无需更新突触连接权重。而当最大膜电位大于阈值电位时，需要根据如上公式更新连接权重，且  $\lambda < 0$  以削弱贡献比较大的连接权重。

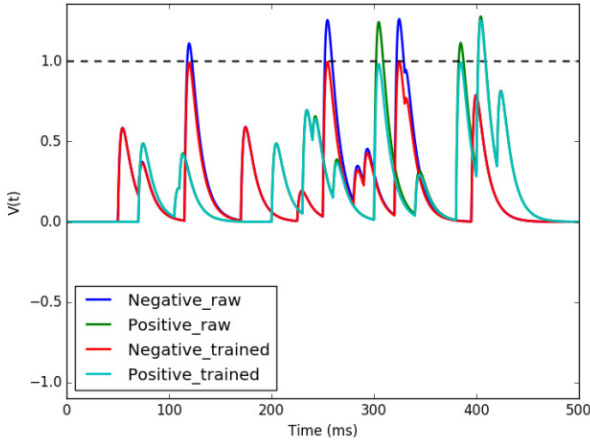


图 6: SNN2

利用 Tempotron 学习规则进行简单的二分类训练，通过下图可以看到输出膜电位的变化。其中，raw 为训练前的膜电位曲线，trained 为训练后的膜电位曲线。可见，训练后的 Positive 类别仍然发放脉冲，而训练后的 Negative 类别样本被抑制发放脉冲，如图 6。

## 6. 深度置信网络

### 6.1. 受限玻尔兹曼机

受限玻尔兹曼机也是一种受生物神经网络系统启发的网络模型。标准的受限玻尔兹曼机由二值（布尔/伯努利）隐层和可见层单元组成。权重矩阵  $W = (w_{i,j})$  中的每个元素指定了隐层单元  $h_j$  和可见层单元  $v_i$  之间的权重。此外对于每个可见层单元  $v_i$  有偏置  $a_i$ ，对每个隐层单元  $h_j$  有偏置  $b_j$ 。在这些定义下，一种受限玻尔兹曼机配置（即给定每个单元取值）的“能量”  $(v,h)$  被定义为

$$E(v, h) = - \sum_i a_i v_i - \sum_j b_j h_j - \sum_i \sum_j h_j w_{i,j} v_i \quad (13)$$

受限玻尔兹曼机的构造如图 7。

目前，受限玻尔兹曼机在多个领域得到了广泛的




图 7: 受限玻尔兹曼机。图中的较上一层神经元组成隐层，较下的神经元组成显元。每一层都可以用一个向量来表示，每一维表示每个神经元。这两层间采用的是对称（双向）连接。

应用，如数据降维 [36]，图像分类 [37]，协同过滤 [38] 等。此外，多个受限玻尔兹曼机的组合可以构成深度置信网络。

### 6.2. 深度置信网络

DBN 是由多层 RBM 组成的一个神经网络，它既可以被看作一个生成模型，也可以当作判别模型，其训练过程是：使用非监督贪婪逐层方法去预训练获得权值。其拓扑结构如下：




图 8: 深度置信网络

## 7. CONCLUSION

Remains...

## 参考文献

- [1] Frank Rosenblatt. Principles of neurodynamics. perceptrons and the theory of brain mechanisms. Technical report, CORNELL AERONAUTICAL LAB INC BUFFALO NY, 1961.
- [2] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *nature*, 521(7553):436, 2015.
- [3] Nelson Morgan and Herve Bourlard. Continuous speech recognition using multilayer perceptrons with hidden markov models. In *Acoustics, Speech, and Signal Processing, 1990. ICASSP-90., 1990 International Conference on*, pages 413–416. IEEE, 1990.
- [4] A Khotanzad and JH Lu. Distortion invariant character recognition by a multilayer perceptron and backpropagation learning. In *IEEE International Conference on Neural Networks*, volume 1, pages 625–632, 1988.
- [5] Yi Kai, Chen Shitao, Chen Yu, Xia Chao, and Zheng Nan-ning. Cognition-based deep learning: Progresses and perspectives. In *Internation Conference on Artificial Intelligence Applications and Innovations*, 2018.
- [6] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in neural information processing systems*, pages 1097–1105, 2012.
- [7] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*, 2014.
- [8] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Alex Graves, Ioannis Antonoglou, Daan Wierstra, and Martin Riedmiller. Playing atari with deep reinforcement learning. *arXiv preprint arXiv:1312.5602*, 2013.
- [9] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A Rusu, Joel Veness, Marc G Bellemare, Alex Graves, Martin Riedmiller, Andreas K Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529, 2015.
- [10] John J Hopfield. Neural networks and physical systems with emergent collective computational abilities. *Proceedings of the national academy of sciences*, 79(8):2554–2558, 1982.
- [11] Dmitry Krotov and John J Hopfield. Dense associative memory for pattern recognition. 2016.
- [12] Donald Olding Hebb. *The organization of behavior: A neuropsychological theory*. Psychology Press, 2005.
- [13] Simon Haykin. Neural networks: a comprehensive foundation, 1999. *Mc Millan, New Jersey*, 2010.
- [14] Dmitry Krotov and John J Hopfield. Dense associative memory is robust to adversarial inputs. *arXiv preprint arXiv:1701.00939*, 2017.
- [15] Teuvo Kohonen. *Self-organization and associative memory*, volume 8. Springer Science & Business Media, 2012.
- [16] Berndt Müller, Joachim Reinhardt, and Michael T Strickland. *Neural networks: an introduction*. Springer Science & Business Media, 2012.
- [17] Li Yaoyong. Associative memory model: Hopfield neural network and dynamic neural network (chinese). In *PHD thesis of Xi'an Jiaotong University*, 1998.
- [18] John Michael Tutill Thompson and H Bruce Stewart. *Non-linear dynamics and chaos*. John Wiley & Sons, 2002.
- [19] Christine A Skarda and Walter J Freeman. How brains make chaos in order to make sense of the world. *Behavioral and brain sciences*, 10(2):161–173, 1987.
- [20] A Babloyantz, JM Salazar, and C Nicolis. Evidence of chaotic dynamics of brain activity during the sleep cycle. *Physics letters A*, 111(3):152–156, 1985.
- [21] Carl Doersch. Tutorial on variational autoencoders. *arXiv preprint arXiv:1606.05908*, 2016.
- [22] Philip Bachman and Doina Precup. Data generation as sequential decision making. *CoRR*, abs/1506.03504, 2015.
- [23] Sebastian J Wetzel. Unsupervised learning of phase transitions: From principal component analysis to variational autoencoders. *Physical Review E*, 96(2):022140, 2017.
- [24] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *Advances in neural information processing systems*, pages 2672–2680, 2014.
- [25] Christian Ledig, Lucas Theis, Ferenc Huszár, Jose Caballero, Andrew Cunningham, Alejandro Acosta, Andrew Aitken, Alykhan Tejani, Johannes Totz, Zehan Wang, et al. Photo-realistic single image super-resolution using a generative adversarial network. *arXiv preprint*, 2016.

- [26] Lantao Yu, Weinan Zhang, Jun Wang, and Yong Yu. Seqgan: Sequence generative adversarial nets with policy gradient. In *AAAI*, pages 2852–2858, 2017.
- [27] Wolfgang Maass. Networks of spiking neurons: the third generation of neural network models. *Neural networks*, 10(9):1659–1671, 1997.
- [28] Alan L Hodgkin and Andrew F Huxley. A quantitative description of membrane current and its application to conduction and excitation in nerve. *The Journal of physiology*, 117(4):500–544, 1952.
- [29] Eugene M Izhikevich. Simple model of spiking neurons. *IEEE Transactions on neural networks*, 14(6):1569–1572, 2003.
- [30] Wulfram Gerstner and Werner M Kistler. *Spiking neuron models: Single neurons, populations, plasticity*. Cambridge university press, 2002.
- [31] Henry Markram, Joachim Lübke, Michael Frotscher, and Bert Sakmann. Regulation of synaptic efficacy by coincidence of postsynaptic aps and epsps. *Science*, 275(5297):213–215, 1997.
- [32] Guo-qiang Bi and Mu-ming Poo. Synaptic modifications in cultured hippocampal neurons: dependence on spike timing, synaptic strength, and postsynaptic cell type. *Journal of neuroscience*, 18(24):10464–10472, 1998.
- [33] Robert Güttig and Haim Sompolinsky. The tempotron: a neuron that learns spike timing–based decisions. *Nature neuroscience*, 9(3):420, 2006.
- [34] Filip Ponulak. Resume-new supervised learning method for spiking neural networks. *Institute of Control and Information Engineering, Poznan University of Technology*, 42, 2005.
- [35] Sander M Bohte, Joost N Kok, and Han La Poutre. Error-backpropagation in temporally encoded networks of spiking neurons. *Neurocomputing*, 48(1-4):17–37, 2002.
- [36] Geoffrey E Hinton and Ruslan R Salakhutdinov. Reducing the dimensionality of data with neural networks. *science*, 313(5786):504–507, 2006.
- [37] Hugo Larochelle and Yoshua Bengio. Classification using discriminative restricted boltzmann machines. In *Proceedings of the 25th international conference on Machine learning*, pages 536–543. ACM, 2008.
- [38] Ruslan Salakhutdinov, Andriy Mnih, and Geoffrey Hinton. Restricted boltzmann machines for collaborative filtering. In

*Proceedings of the 24th international conference on Machine learning*, pages 791–798. ACM, 2007.